

گزارش تکلیف شماره ۰ کامپیوتری / دکتر وهابی / امیر محمد میر حسینی ۸۱۰۱۰۲۶۰۱

سوال ۱:

📁 .ipynb_checkpoints	17/10/2024 13:53	File folder	
📁 __pycache__	17/10/2024 14:25	File folder	
📄 # Q2_EPS_CA0_v2	18/10/2024 18:09	Python Source File	4 KB
📄 # Q3_EPS_CA0 FIRST PART	20/10/2024 22:39	Jupyter Source File	17 KB
📄 # Q3_EPS_CA0 SECOND PART	20/10/2024 22:40	Python Source File	3 KB
📄 numpy_basic	17/10/2024 14:29	Jupyter Source File	92 KB
📄 numpy_basic	17/10/2024 14:25	Python Source File	20 KB

سوال ۲:


📁 .ipynb_checkpoints	17/10/2024 13:53	File folder	
📁 __pycache__	17/10/2024 14:25	File folder	
📄 # Q2_EPS_CA0_v2	18/10/2024 18:09	Python Source File	4 KB
📄 # Q3_EPS_CA0 FIRST PART	20/10/2024 22:39	Jupyter Source File	17 KB
📄 # Q3_EPS_CA0 SECOND PART	20/10/2024 22:40	Python Source File	3 KB
📄 numpy_basic	17/10/2024 14:29	Jupyter Source File	92 KB
📄 numpy_basic	17/10/2024 14:25	Python Source File	20 KB

۲-الف) احتمال حالات معین شده به شرح زیر است:

[0.967365028203062, 0.9988631799564817, 0.032634971796937945, 0.5, 0.5]


(1)	(2)	(3)	(4)	(5)
-----	-----	-----	-----	-----

۲-ب) دفعات شبیه سازی: ۲۰۰۰ بار / P از ۰ تا ۱ در نظر گرفته شد.




۲-ج) همانطور که در نمودار سوال قبل مشخص شد، $P=0.9$ جواب مدنظر می باشد.

۲-د) برای این سوال اکثریت را از ۲۶ تا ۵۰ تعریف کرده و نمایش می دهیم. این سوال مرتبط به هر دو بخش الف و ب بوده و در این سوال n و p را مورد تغییر قرار می دهیم.




برای درک بهتر از این نمودار نیز استفاده شده است. هیت مپ مدنظر سوال نیز در صفحه بعد آمده است.



توجه داشته باشید که n از ۰ تا ۵۰ در نظر گرفته نشده زیرا اکثریت از ۲۶ شروع می‌شود.

اما اگر n را از ۰ تا ۵۰ در نظر بگیریم هیت‌مپ زیر را خواهیم داشت. (در کد ارسالی آورده نشده است).



سوال ۳:

📁 .ipynb_checkpoints	17/10/2024 13:53	File folder	
📁 __pycache__	17/10/2024 14:25	File folder	
📄 # Q2_EPS_CA0_v2	18/10/2024 18:09	Python Source File	4 KB
📄 # Q3_EPS_CA0 FIRST PART	20/10/2024 22:39	Jupyter Source File	17 KB
📄 # Q3_EPS_CA0 SECOND PART	20/10/2024 22:40	Python Source File	3 KB
📄 numpy_basic	17/10/2024 14:29	Jupyter Source File	92 KB
📄 numpy_basic	17/10/2024 14:25	Python Source File	20 KB

بخش اول مربوط به قبل از پرسش‌های سوالات: **مراحل سوال** می‌باشد.
از sklearn.model و pandas, numpy, seaborn استفاده شده است.

(۱) پیش‌پردازش داده‌ها

```
~ Loading Data

dataset = pd.read_csv('emails.csv')
[82]

Preprocessing

def lower(s):
    return s.lower()

lower_vectorized = np.vectorize(lower)

dataset['text'] = lower_vectorized(dataset['text'])
[83]

def remove_special_characters(s):
    special_characters = '!@#%^&*().,/=-+_*'
    for i in special_characters:
        s = s.replace(i, ' ')
    return s

def remove_white_spaces(s):
    return re.sub(r'\s+', ' ', s)

remove_white_spaces = np.vectorize(remove_white_spaces)

remove_characters_vectorized = np.vectorize(remove_special_characters)
```

(۲) تقسیم به داده آزمایش و آموزش

Train/Test Split

```
x = pd.DataFrame()
x['text'] = dataset['text']

x_train, x_test, y_train, y_test = train_test_split(x, dataset['spam'], test_size = 0.33)

x = pd.DataFrame()
x['text'] = x_train['text']
x['label'] = y_train
```

x

	text	label
4023	subject: followup forwarded by patricia tlapek...	0
3115	subject: re : vacation shirley no problem vinc...	0
1158	subject: clear benefits of creative design It ...	1
2557	subject: re : test thanks vince we have receiv...	0
5080	subject: re : turkey the group to whom this me...	0
...	...	...
1924	subject: hedging vince : the attached article ...	0
2508	subject: re : time david : i have you schedule...	0
1021	subject: re : time david : i have you schedule...	0

(۳) ساخت ماتریس BoW

BoW Matrix

```
all_words = set()
all_texts = x_train['text']

for text in all_texts:
    words = text.split(' ')
    for word in words:
        all_words.add(word)

all_words = list(all_words)
```

```
BoW = []

def word_count(s, word):
    series = []

    for string in s:
        series.append(string.count(word))
    return series

for word in all_words:
    BoW.append(word_count(all_texts, word))
```

```
BoW = np.array(BoW)
```

۴) پیش‌بینی با استفاده از قانون بیز (محاسبه دقت)

دقت مدل ۷۶ درصد است.

```
accuracy = []
y_test = np.array(y_test)

def bool_to_int(b):
    if b:
        return 1
    return 0

for i in range(len(y_predicted)):
    if bool_to_int(y_predicted[i]) == y_test[i]:
        accuracy.append(1)
    else:
        accuracy.append(0)

accuracy = np.array(accuracy)
accuracy = int(accuracy.sum()/len(accuracy) * 100)
```

94]

accuracy

95]

76

پرسش‌ها: در فایل قسمت دوم سوال ۳ تغییرات خواسته شده ایجاد شده:

سوال ۱-۳:

این روش به ما کمک می‌کند تا از بروز احتمال صفر برای کلمات ناشناخته جلوگیری کنیم.

در این روش، به تعداد ظهور هر کلمه ۱ واحد اضافه می‌شود و همچنین به کل تعداد کلمات نیز به تعداد کل کلمات منحصر به فرد، اضافه می‌شود. این به ما این امکان را می‌دهد که حتی اگر یک کلمه در یک دسته (مثلاً اسناد اسپم) وجود نداشته باشد، برای آن یک احتمال غیر صفر در نظر بگیریم.

در پروژه در فایل بخش دوم استفاده شد.

سوال ۲-۳: در پروژه استفاده نشده است.

سوال ۳-۳: در پروژه پیاده سازی شد، دقت از ۷۶ به ۵۰ درصد کاهش یافت.

```
FS C:\Users\alim17 & C:\Users\alim17\AppData
Predictions:
      text  predicted
0  Win a million dollars    False
1      Hi there!           False
Accuracy: 50.00%
```